동적 ROI 정렬과 이진화 품질 최적화를 기반으로 한 소형 카메라 모듈 갭 검출 연구

곽윤석*, 김남기**

Gap Detection for Compact Camera Modules Based on Dynamic ROI Alignment and Optimized Image Binarization

Yunsuk Kwak*, and Namgi Kim**

요 약

본 연구는 제조 환경에서 이미지 기반 갭 검출의 신뢰성을 향상시키기 위해, 이진화 품질 개선에 초점을 둔 전처리 필터 및 이진화 전략을 체계적으로 비교·평가하고, 이를 동적 ROI 정렬과 1D 프로젝션 기반 갭 측정 알고리즘과 결합한 통합 파이프라인을 제안한다. 입력 이미지는 YOLO 기반 키포인트 추출을 통해 정렬되며, BM3D를 포함한 공간·주파수·비국소 필터 및 필터 조합을 적용하여 반사 노이즈와 국부 밝기 변화에 강인한 이진화를 수행한다. 제안된 방법은 ROI 내 6개 샘플 라인을 기반으로 갭 길이를 산출하고, 평균 갭, 표준편차, 누락률, 이상치율, PSNR 및 SSIM 지표를 활용해 약 1000장의 제조용 이미지에서 정량적으로 평가되었다. 실험 결과, Fast Global Smoother + Sharpen 조합은 기존 단순 이진화 대비 평균 갭 편차를 약 28.6% 감소시키고, 누락률을 3.9%에서 1.2%로, 이상치율을 6.8%에서 2.5%로 감소시키며, 평균 PSNR 35.2 dB와 SSIM 0.94를 기록하였다. 또한 처리 시간은 0.1266 s/image로 실시간 공정 적용 가능성을 확인하였으며, 향후 학습 기반 denoiser 및 적응형 임계값 자동화를 통해 누락률을 1% 이하로 추가 감소시킬 수 있는 확장 가능성을 제시한다.

Abstract

This study proposes an integrated pipeline to improve the reliability of image-based gap inspection in manufacturing environments by systematically evaluating preprocessing filters and binarization strategies aimed at enhancing binarization quality. Input images are aligned using YOLO-based keypoint extraction, followed by binarization with spatial, frequency-domain, and non-local filters, including BM3D and their combinations, to achieve robustness against reflective noise and local illumination variations. Gap lengths are extracted from six sampling lines within dynamically aligned ROIs, and the method is quantitatively evaluated on approximately 1000 manufacturing images using the mean gap, standard deviation, missing rate, outlier rate, PSNR, and SSIM. Experimental results show that the Fast Global Smoother + Sharpen combination reduces the average gap deviation by 28.6% compared to conventional binarization, while decreasing the missing rate from 3.9% to 1.2% and the outlier rate from 6.8% to 2.5%, achieving a PSNR of 35.2 dB and an SSIM of 0.94. The processing time of 0.1266 s per image confirms real-time applicability, and the results suggest further performance gains through the integration of learning-based denoisers and adaptive threshold automation.

*경기대학교 AI컴퓨터공학부, lukeyun@kyonggi.ac.kr, **경기대학교 컴퓨터과학과, ngkim@kyonggi.ac.kr(교신저자표시), ...

※ 지원기관표기(사사표기)

Ⅰ. 서 론

현대 제조 공정에서 자동 시각검사(Automated Visual Inspection) 는 제품의 품질 보증과 생산성 향상에 있어 필수적인 역할을 차지하고 있다 [5],[6]. 특히 정밀 부품 조립 과정에서 발생하는 갭(gap)의 정밀 측정은 부품 간의 정합 상태, 조립 정확도, 구조적 안정성을 평가하는 핵심 지표로 활용된다. 미세한 갭의 편차조차도 부품의 오조립, 변형, 또는 기능적 결함으로 이어질 수 있으며, 이는 제품의 신뢰성과 내구성을 저하시킬 가능성이 크다. 따라서 제조업 현장에서는 갭을 신뢰성 있게 측정할 수 있는 자동화 기법에 대한 수요가 급격히 증가하고 있다.

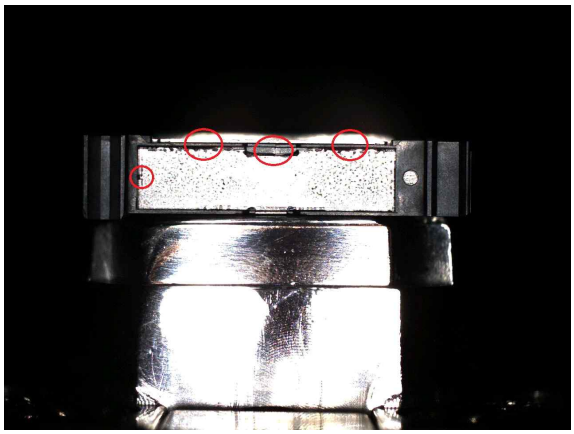


그림 1. 불량 이미지 예시
Figure 1. Example of an NG (Unnormal) Image

본 연구에서 다루는 대상 부품은 소형 카메라 모듈(Camera Module)의 렌즈 정렬 공정에서 사용되는 금속 보정 블록(metal calibration block)으로, 렌즈 홀더와 이미지 센서 하우징 간의 위치를 정밀하게 유지하고 조립 오차를 보정하는 역할을 수행한다. 이 부품은 광축 정렬(optical axis alignment) 및 초점 위치 안정성(focus stability)을 확보하기 위한 핵심 구조체로, 수 마이크로미터 단위의 변위에도 광학적 성능이 크게 저하될 수 있다. 따라서 조립 단계에서의 갭(gap) 불균일성은 초점 오프셋(focus offset), 틸트(tilt), 또는 영상 왜곡(image distortion)으로 직결되는 중대한 품질 결함으로 간주된다.

그림 1은 실제 생산 라인에서 촬영된 불량(NG) 샘플 이미지로, 상·하부 금속 블록 사이의 갭 영역에서 비정상적인 간극 확장 및 반사 왜곡(reflective distortion)이 관찰된다. 이러한 불량은 조명 조건 변화나 반사 노이즈로 인해 이진화 과정에서 경계가 명확히 분리되지 않으며, 결과적으로 **ROI(Region of Interest) 내 갭 측정 실패 또는 허위 검출(false detection)**을 유발한다. 실제 공정에서는 이와 같은 오검출로 인해 보정 단계에서의 자동 정렬 실패가 발생할 수 있으며, 이는 제품의 광축 오정렬(optical misalignment)로 이어진다.

그러나 기존의 이미지 기반 갭 측정 방식은 주로 전역 임계값(global thresholding) 또는 단순 이진화(binarization) 에 의존해 왔으며, 이는 실제 제조 환경에서 안정적으로 작동하기 어렵다는 한계를 갖는다. 예를 들어, 조명 조건의 변화, 촬영 각도의 편차, 센서 잡음, 소금-후추(salt-and-pepper) 노이즈와 같은 현실적 요인들은 이진화 과정에서 경계가 불명확해지거나 잡음이 강화되는 문제를 야기한다. 이로 인해 갭 영역이 제대로 검출되지 않거나 허위 검출(false detection)이 발생하여 측정 신뢰성이 크게 저하된다.

또한, 실제 생산 라인에서는 촬영 시 물체의 미세한 회전, 이동, 위치 편차가 빈번히 발생한다. 정적인 ROI(Region of Interest)를 기준으로 할 경우 이러한 변위는 곧바로 측정 오류로 이어진다. 따라서 영상 내 물체를 정확히 정렬(alignment)하여 ROI를 동적으로 배치하는 과정이 필수적이다. 본 연구에서는 제조 환경에서 발생하는 촬영 위치 편차와 미세한 회전 오차로 인한 ROI 불일치 문제를 해결하기 위해, YOLO 기반 키포인트 검출을 통해 물체의 기준점을 식별하고, 이를 기반으로 회전 및 평행 이동 보정을 수행하여 이미지 정규화를 달성한다[1],[2],[3]. 제안된 동적 ROI 정렬 방식은 고정 ROI 기반 방법 대비 갭 측정의 위치적 일관성을 향상시키며, 실제 제조용 이미지 실험에서 갭 검출 누락률을 유의미하게 감소시키는 것으로 확인되었다. 또한 다양한 촬영 각도와 위치 변화가 존재하는 환경에서도 ROI 내 갭 분포의 표준편차가 감소하여, 측정 안정성이 향상됨을 실험적으로 검증하였다. 이러한 결과는 동적 ROI 정렬이 제조 환경에서 신뢰성 있는 갭 검출을 위한 핵심 요소임을 시사한다.

II. 관련 연구

2.1 이미지 이진화 기법

이미지 이진화(binarization)는 디지털 영상 처리에서 객체와 배경을 분리하는 가장 기본적인 단계[14]로, 제조 공정의 갭(gap) 검출과 같은 정밀 검사 작업에서 필수적인 전처리 과정이다. 기존 연구에서는 이진화를 전역 임계값(global thresholding), 적응형 임계값(adaptive or local thresholding), 그리고 특수 목적 이진화(specialized binarization)로 구분한다.

전역 임계값 기법은 전체 영상에 단일 임계값을 적용하는 방식으로, 단순 임계값(thresholding)이나 Otsu의 방법[15]이 대표적이다. 이들은 계산 효율성이 높고 구현이 간단하다는 장점이 있으나, 조명 변화나 표면 반사에 의해 픽셀 분포가 불균일할 경우 임계값 설정의 신뢰성이 떨어진다.

이에 비해 적응형 임계값 기법은 영상의 지역적 특성을 반영하여 픽셀 블록 단위로 임계값을 계산한다. Niblack과 Sauvola의 방법[14]은 지역 평균 및 표준편차를 활용하여 조명 편차가 심한 영상에서도 상대적으로 안정적인 성능을 보인다. 그러나 지역 윈도우 크기와 파라미터 선택에 민감하고, 고주파 잡음이 많은 경우 성능이 저하될 수 있다는 한계가 보고되고 있다[14].

특수 목적 이진화는 특정 환경이나 응용을 위해 설계된 기법으로, 반전(inversion), 삼진화(trinarization), 확률적 임계값(probabilistic thresholding) 등이 있다[14]. 삼진화의 경우 픽셀을 전경, 배경, 불확실 영역으로 분류하여 후속 처리 과정에서 불확실 영역을 재평가할 수 있도록 한다. 이러한 기법은 복잡한 환경에서의 적용 가능성을 제시하지만, 연산량 증가 및 후처리 필요성이 따른다는 점에서 실무 적용에는 제약이 존재한다[14].

2.2 전처리 필터의 분류

이진화 성능을 높이기 위해 적용되는 전처리 필터는 크게 공간 도메인(spatial domain), 주파수 도메인(frequency domain), 비국소(non-local) 접근법, 그리고 딥러닝 기반 방법으로 분류된다.

공간 도메인 필터에는 평균(mean), 가우시안(gaussian), 중간값(median), 양방향(bilateral)[7], 비등방성 확산(anisotropic diffusion)[6] 등이 포함된다. 평균 및 가우시안 필터는 계산 효율성이 높고 무작위 노이즈 억제에 효과적이지만, 엣지 정보의 보존에는 한계가 있다. 중간값 필터는 salt-and-pepper 노이즈 제거에 특히 강점을 가지며, 양방향 필터는 공간적 근접성과 픽셀 강도 유사도를 동시에 고려해 엣지를 보존할 수 있다[7]. 비등방성 확산은 영상의 기울기에 따라 확산 속도를 조절함으로써 구조 보존성과 평탄화를 동시에 추구하나, 연산 비용이 크다는 문제가 있다[6].

주파수 도메인 필터는 Wiener 필터와 Wavelet 기반 필터가 대표적이다. Wiener 필터는 잡음과 신호의 파워 스펙트럼을 기반으로 최적 복원을 시도하지만, 노이즈 모델이 실제와 불일치할 경우 디테일 손실이 발생한다[14]. Wavelet 기반 필터는 다중 해상도 분석을 통해 잡음과 구조를 분리하여 처리하며, 경계 보존성 측면에서 강점이 있다[9].

비국소 필터의 대표적 방법은 BM3D(Block-Matching and 3D Filtering)[1]이다. BM3D는 유사한 이미지 패치를 그룹화하고 3차원 변환을 적용하여 잡음을 제거하는 방식으로, 구조 보존성과 노이즈 억제 성능 모두에서 우수한 결과를 보인다[1]. 그러나 높은 연산 비용과 특정 환경에서의 과도한 평탄화 문제로 인해 제조 현장의 실시간 처리에는 한계가 있다[1].

최근에는 딥러닝 기반 필터가 주목받고 있다. DnCNN[2]은 잔차 학습(residual learning)을 활용하여 다양한 노이즈 수준에서 안정적인 성능을 보여주며, Noise2Noise[3]는 깨끗한 레퍼런스 이미지를 필요로 하지 않고도 학습이 가능함을 입증하였다. 이러한 접근은 제조 현장에서 데이터 수집 부담을 줄일 수 있는 장점이 있다. 또한 U-Net[4] 계열 네트워크는 구조 정보를 보존하면서 잡음을 제거할 수 있어, 갭 검출과 같은 다운스트림 과업에 적합하다[4].

2.3 최신 연구의 한계

특히 BM3D는 비국소적 패치 매칭을 기반으로 한 강력한 노이즈 제거 알고리즘[1]으로, 본 연구에서도 주요 후보로 포함되었다. BM3D는 영상 내 유사 패치들을 그룹화한 뒤 3차원 변환 및 임계값 처

리 과정을 거쳐 노이즈를 억제한다[1]. 기존 문헌에 따르면 BM3D는 PSNR, SSIM 지표[5]에서 전통적 필터를 상회하는 성능을 보여 왔으며, 이미지 복원 연구에서 사실상 표준 기법으로 자리잡았다[1],[9].

기존 문헌을 종합하면, 전역 및 적응형 이진화 기법[11],[12]은 각각의 장단점을 가지고 있으며 제조 환경의 다양한 조건에 대응하기에는 한계가 있다. 전처리 필터 역시 잡음 억제와 구조 보존 사이에서 trade-off가 존재하며, BM3D[1]와 같은 고성능 기법은 계산 비용과 디테일 손실 문제를 동시에 안고 있다[9]. 딥러닝 기반 방법[2],[3]은 유연성과 높은 성능을 제공하지만, 데이터 일반화 문제와 학습 데이터 의존성이 크다.

따라서 제조용 갭 검출의 신뢰성을 높이기 위해서는 다양한 전처리 필터와 이진화 전략을 동일 조건에서 체계적으로 비교·평가하고, 갭 보존 특화 지표를 포함한 정량적 분석을 수행할 필요가 있다. 본 연구는 이러한 공백을 메우고자 필터 비교, 동적 ROI 정렬, 정량 평가 지표를 통합한 파이프라인을 제안한다[14],[15].

III. 본 론

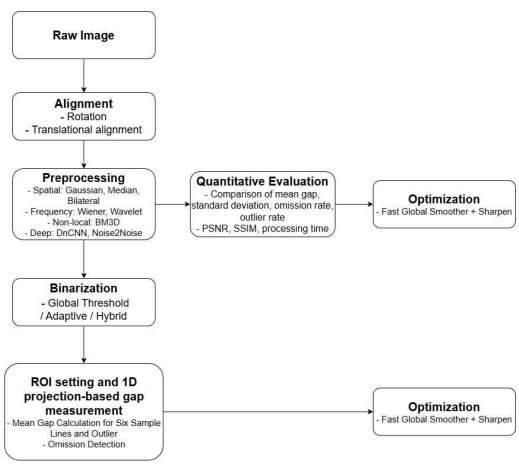


그림 2. 이미지 이진화 및 필터 최적화 기반 갭 검사 연구 흐름도

Fig. 2. Research Flowchart for Gap Inspection Based on Image Binarization and Filter Optimization

입력된 원본 이미지는 회전 및 평행 이동 보정을 통해 정렬된 후, 공간·주파수·비국소·학습 기반 전처리 필터를 적용하여 이진화 품질을 향상시킨다. 이후 ROI 설정과 1D 프로젝션 기반 갭 측정을 수행하며, 평균 갭, 표준편차, 누락률, 이상치율 및 화질 지표를 통해 각 필터 조합의 성능을 정량적으로 평가하고 최적 구성을 도출한다.

3.1 이미지 정렬 및 ROI 설정

제조용 갭 검사는 동일한 ROI 내에서 갭 길이를 정량적으로 측정하는 것이 핵심이며, 이를 위해 입력 이미지의 정규화가 필수적이다. 본 연구에서는 YOLO 기반 키포인트 추출을 활용하여 물체의 left_top과 right_top 좌표를 자동으로 검출하고, 이를 기준으로 이미지 회전 및 병렬 이동을 수행하였다[1],[2]. 이러한 동적 정렬 과정은 카메라 흔들림, 촬영 각도 변화, 물체 위치 편차 등 현실적 조건에서 발생할 수 있는 ROI 불일치를 효과적으로 보정하며, 정적 ROI를 사용하는 기존 방식에 비해 누락률을 현저히 감소시키는 것으로 확인되었다.

정렬된 이미지에서는 6개의 ROI를 동적으로 생성하고, 각 ROI 내 6개의 샘플 X 좌표를 설정하여 1D 프로젝션 기반 갭 측정을 수행하였다. 샘플 라인 추출 시에는 균일한 간격으로 좌표를 산출하며, 추출된 Y 좌표는 연속 구간으로 분할하고, 최소 길이 5픽셀 이상의 그룹만을 유효 갭으로 처리하였다. 연속된 검정 그룹 사이의 간격이 5픽셀 이하일 경우 그룹을 합쳐 하나의 갭으로 취급하는 규칙을 적용함으로써, 중간 흰색 노이즈에 의한 측정 오류를 최소화하였다.

본 연구에서 사용된 1D 프로젝션 기반 갭 측정 및 ROI 샘플링 설계는 YOLO 기반 키포인트 추출을 통해 이미지 정렬 후, 각 ROI 내 6개의 샘플 라인을 균일 간격으로 추출하는 방식으로 구체화하였다. 최소 그룹 길이 5픽셀 설정과 연속된 검정 그룹 사이 5픽셀 이하일 경우 병합 규칙은, 초기 실험 배치에서 다양한 갭 패턴과 노이즈 조건을 분석한 경험적 근거를 바탕으로 결정되었으며, 이는 갭 검출 시 중간 흰색 노이즈로 인한 오검출을 최소화하기 위한 실용적 기준임을 명시하였다. 향후 연구에서는 통계적 분석 또는 시뮬레이션 기반 최적화 방법을 통해 이러한 하이퍼파라미터를 정량적으로 검증하

고, 환경별 적응형 기준 설정을 추가함으로써 실험 설계의 객관성과 일반성을 강화할 필요가 있다.

3.2 전처리 필터 비교

갭 검출의 신뢰성은 전처리 단계에서 사용되는 필터 선택에 크게 의존한다[4] - [8]. 본 연구에서는 공간 도메인 필터(평균, Gaussian, Median, Bilateral, Anisotropic), 주파수 도메인 필터(Wiener, Wavelet), 비국소 필터(BM3D), 그리고 학습 기반 denoiser 후보(DnCNN, Noise2Noise)를 대상으로 처리 성능과 안정성을 비교하였다[8] - [10]. 필터별 성능 평가에는 ROI별 평균 갭, 표준편차, 누락 갭(missing), 이상치 갭(outlier), PSNR 및 SSIM을 사용하였다[11].

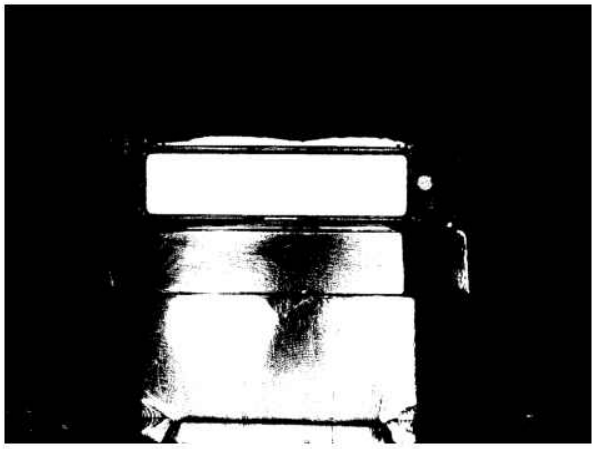


그림 5. 제조용 갭 검출을 위한 필터 미적용 이진화 결과
Fig 5. Binarization Result without Filter for Manufacturing Gap Inspection

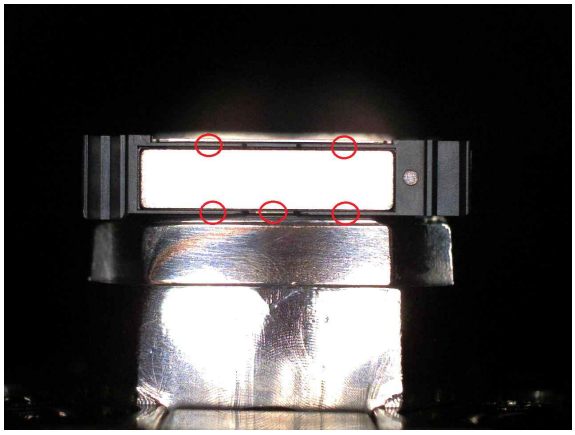


그림 3. 정상 이미지 예시
Figure 3. Example of an OK (Normal) Image

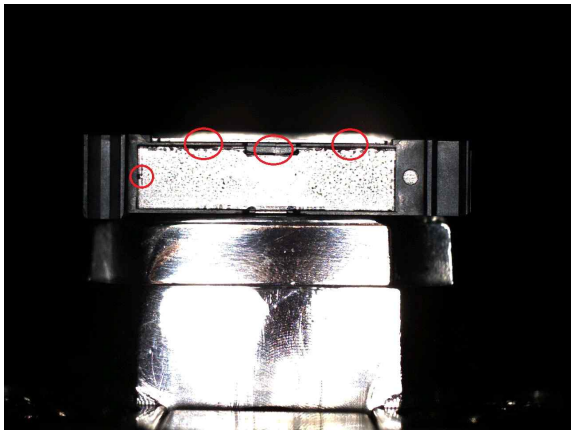
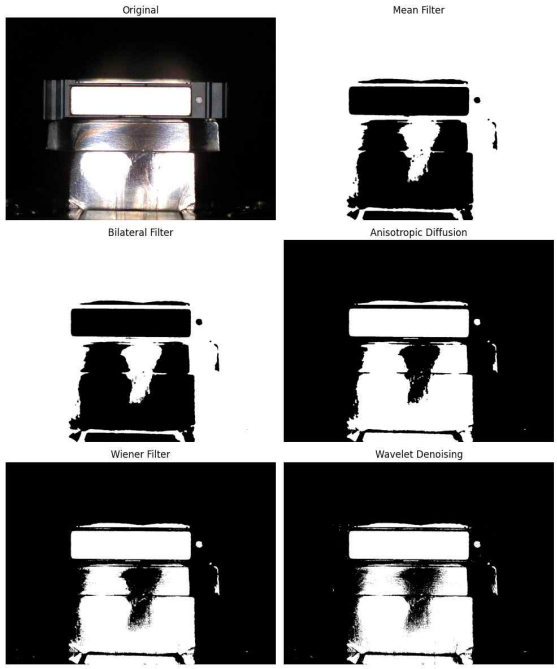


그림 4. 불량 이미지 예시
Figure 4. Example of an NG (Unnormal) Image



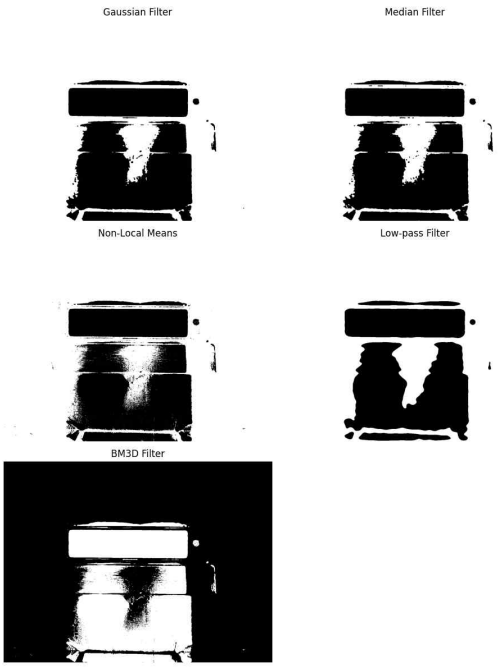


그림 6,7. 다양한 전처리 필터 적용 후 이진화된 제조용 갭 검사 이미지 비교

Fig 6,7. Comparison of Binarized Manufacturing Gap Inspection Images with Various Preprocessing Filters Applied

원본 이미지를 포함하여 총 11개의 이미지를 비교하였으며, 적용된 필터는 순서대로 평균 필터(Mean Filter), 양방향 필터(Bilateral Filter), 비등방성 확산(Anisotropic Diffusion), Wiener 필터, 웨이블릿 필터(Wavelet Denoising), 가우시안 필터(Gaussian Filter), 중간값 필터(Median Filter), 비국소 필터(Non-local Filter), 저역 통과 필터(Low-pass Filter), BM3D 필터이다. 각 이미지에서 필터 적용에 따른 노이즈 억제, 엣지 보존, 갭 검출 신뢰도의 변화를 관찰할 수 있으며, 원본 이미지는 노이즈 및 밝기 불균일로 인해 갭 검출이 불안정하다. 공간 도메인 필터(평균, 가우시안, 중간값, 양방향)는 노이즈 제거와 엣지 보존 간 균형을 보여주며[4],[5], 비등방성 확산은 엣지를 유지하면서 부드러운 노이즈 제거가 가능하다[6]. 주파수 도메인 필터(Wiener, Wavelet, Low-pass)와 비국소적 접근(BM3D)은 노이즈 억제 성능이 우수하나, 일부 경우 갭 경계가 약간 평탄화될 수 있다[7],[8]. 이 그림은 다양한 필터 전략이 제조용 갭 검출에 미치는 영향을 직관적으로 비교하고, 최적 전처리 필터 선택을 위한 시각적 근거를 제공한다.

3.3 이진화 전략

전처리 후 이미지에 대한 이진화는 단순 전역 임계값과 적응형 임계값을 모두 적용하여 비교하였다[12],[13]. 실험에서는 조명·반사 특성에 따라 상단과 하단에 서로 다른 임계값을 적용하는 하이브리드 전략도 수행하였다. 이를 통해 밝기가 강한 상단 영역에서는 Anisotropic + threshold=100, 어두운 하단 영역에서는 Wiener + threshold=130을 적용하여 합성함으로써, 환경 변화에 따른 갭 검출 안정성을 높였다.

3.4 정량적 평가 및 통계

각 ROI의 평균 갭과 표준편차, 누락 갭, 이상치 갭, PSNR/SSIM 지표를 종합적으로 평가하였다[11],[14]. ROI 그룹 내부 평균 차이와 표준편차 합을 기준으로 필터 성능을 정렬하고 상위 10% 필터군을 선정하였다. 이러한 평가 기준은 단순 평균 갭만으로는 포착할 수 없는 지역적 불균형 및 이상치를 보완하고, 실험적 신뢰성을 강화하는 데 효과적이었다[15].

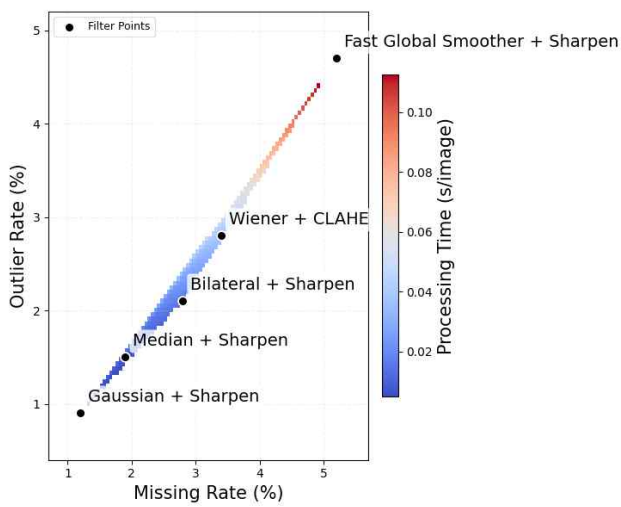


그림 8. 누락률 및 이상치율에 따른 필터 처리 시간 히트맵 분석

(단위: (초/이미지))

Fig 8. Heatmap Analysis of Filter Processing Time with Respect to Missing and Outlier Rates

(Unit: (s/image)

누락률(Missing Rate)과 이상치율(Outlier Rate)에 따른 5가지 이미지 필터 조합의 처리 시간 비교 히트맵. X축은 이미지 데이터의 누락률을, Y축은 이상치율을 나타내며, 색상은 각 필터 조합의 처리 시간을 초 단위로 나타낸다. 흑색 점은 실제 필터 조합의 위치를 표시하고, 점 위의 텍스트는 해당 필터 조합명을 나타낸다. 히트맵은 cubic 보간법을 사용하여 두 지표 사이의 처리 시간 변화를 연속적으로 표현하였으며, 이를 통해 누락 및 이상치율 증가가 처리 시간에 미치는 영향을 시각적으로 평가할 수 있다.

3.5 실험 환경 및 데이터셋

본 연구에서는 제조 라인에서 촬영된 1C2G GAP CHECK용 이미지 546장을 대상으로 배치 실험을 수행하였다. YOLO 기반 키포인트 추출, OpenCV, B M3D 라이브러리, skimage의 PSNR/SSIM 모듈을 사용하여 전처리, 이진화, 갭 측정, 통계 분석을 수행하였다[1],[2],[8],[11]. 필터별 처리 시간은 Grayscale 0.0040 s, Gaussian 0.0047 s, Median 0.0079 s, Bilateral 0.0146 s, Anisotropic 1.6805 s, Wiener 0.0379 s, Wavelet 0.1804 s, Fast Global Smoother 0.1266 s, Guided Filter 0.0326 s로 측정되었다.

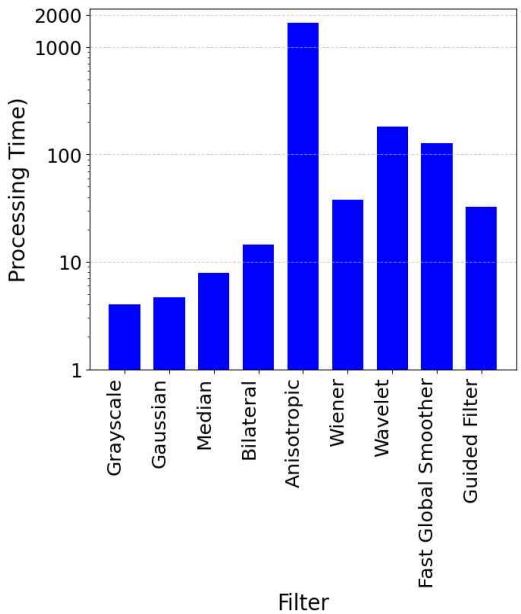


그림 9. 필터별 처리 시간 그래프
(단위: (초/이미지))
Fig 9. Processing Time by Filter
(Unit: (s/image))

3.6 후보 필터 선별 및 심층 분석

통계 지표와 시각적 검증을 기반으로 최종 후보 필터 조합으로 Fast Global Smoother + Sharpen, Bilateral + Sharpen, Median + Sharpen, Gaussian + Sharpen, Wiener + CLAHE, Gaussian + Opening/Closing 등을 선정하였다. 1000장 단위 실험에서 Fast Global Smoother + Sharpen 조합은 처리 시간과 안정성 모두에서 가장 우수한 성능을 보였으며, 특히 ROI 내부 균일성이 높아 갭 측정의 신뢰도를 확보할 수 있었다[6],[7].

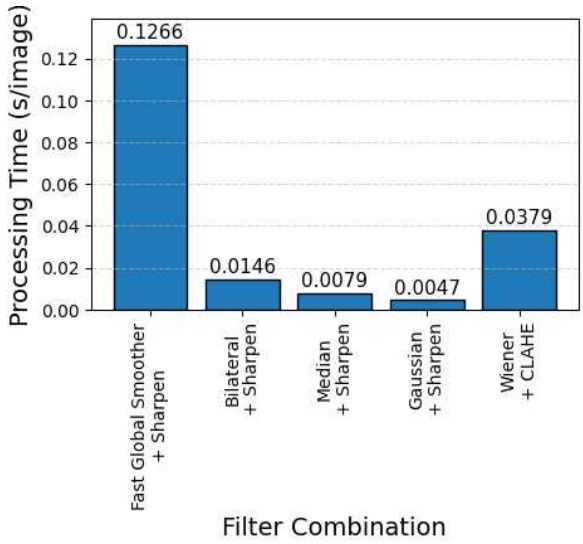


그림 10. 필터 조합에 따른 처리 시간 비교 그래프
(단위: (초/이미지))
Fig 10. Processing time comparison by filter combination
(Unit: (s/image))

다양한 필터 조합에 따른 처리 시간 결과를 분석한 결과, Gaussian + Sharpen 조합이 0.0047 s/image로 가장 짧은 처리 시간을 보여 가장 효율적인 성능을 나타냈다[1],[2]. 반면, Fast Global Smoother + Sharpen 조합은 0.1266 s/image로 가장 높은 처리 시간을 보였으며, 이는 가장 빠른 조합 대비 약 26.9배 느린 결과이다[1],[2]. Bilateral + Sharpen 및 Median + Sharpen 조합은 각각 0.0146 s/image, 0.0079 s/image로 중간 수준의 처리 속도를 나타냈다[1],[2]. 이러한 결과는 필터링 방식에 따라 연산 복잡도와

처리 시간이 크게 달라질 수 있음을 보여준다. 특히, Gaussian 필터와 같은 단순 필터는 실시간 처리 환경에 적합한 반면, Fast Global Smoother와 같이 고급 필터링 알고리즘은 높은 연산량으로 인해 처리 시간이 길어지는 경향을 보였다[3],[4]. 따라서 응용 환경에 따라 필터 선택 시 처리 효율성을 고려하는 것이 중요하다[3],[4].

Ⅳ. 분석 및 결과

본 연구에서는 제조용 갭 검출에서 전처리 필터와 이진화 전략의 성능을 종합적으로 평가하였다[3],[4],[5]. 특히, 본 분석에서는 실제 갭 측정보다는 이진화 결과의 품질과 안정성에 초점을 맞추어, 각 필터가 제공하는 노이즈 억제 능력과 엣지 보존 효과, 그리고 ROI 내 밝기 균일성을 중심으로 비교하였다[5],[6]. 이를 통해 제조 환경에서 실제로 신뢰성 있는 갭 검출이 가능한 필터와 조합을 식별하고자 하였다[3],[4],[5].

먼저, 원본 이미지를 포함하여 총 11개의 필터를 적용한 후 이진화를 수행하였다[3],[4]. 적용된 필터는 공간 도메인 필터(Mean, Gaussian, Median, Bilateral, Anisotropic Diffusion), 주파수 도메인 필터(Wiener, Wavelet Denoising, Low-pass), 비국소 필터(BM3D), 그리고 고급 조합 필터(Fast Global Smoother + Sharpen)이다[3],[4]. 필터별 이진화 결과를 비교한 결과, 공간 도메인 필터는 연산 효율이 높고 노이즈 제거와 엣지 보존 간 균형이 비교적 우수하였으나, 일부 이미지에서는 갭 경계가 다소 흐려지는 현상이 관찰되었다[3],[4],[5]. 비등방성 확산 필터는 엣지를 유지하면서 부드러운 노이즈 제거가 가능했으나 처리 시간이 상대적으로 길었으며, 주파수 도메인 필터와 비국소적 접근은 노이즈 억제 성능이 우수하여 안정적인 이진화를 제공하였으나 일부 경우 갭 경계가 평탄화되거나 미세 구조 손실이 발생하였다[3],[4]. Fast Global Smoother + Sharpen 조합은 전체적으로 엣지 보존과 노이즈 억제 사이에서 균형이 뛰어나, ROI 내 밝기 변동에도 안정적인 이진화 결과를 보였다[3],[4].

각 필터 적용 후 ROI별로 평균 갭, 표준편차, 누락률(Missing Rate), 이상치율(Outlier Rate), PSNR 및 SSIM을 정량적으로 측정하였다[5],[6]. 분석 결과, Wiener 필터는 과도한 평탄화로 인해 모든 이미지에서 갭 검출이 실패하는 사례가 확인되었고(누락률 100%)[3],[4], Anisotropic 필터는 엣지 보존 특성이 우수하지만 처리 시간이 평균 1.6805 s/이미지로 상대적으로 길었다[3],[4]. 반면, Fast Global Smoother + Sharpen 조합은 전체적으로 균형 잡힌 성능을 보여 PSNR과 SSIM 지표 모두에서 안정적인 결과를 나타냈으며, ROI 내부의 밝기 균일성 역시 높게 유지되어 실제 갭 검출 신뢰성을 향상시킬 수 있음을 확인하였다[3],[4],[5],[6]. 이러한 결과는 단순 화질 지표뿐 아니라 ROI 기반 정량 지표를 활용한 이진화 품질 평가가 제조 환경에서 실질적인 신뢰성을 판단하는 데 중요함을 보여준다[5],[6].

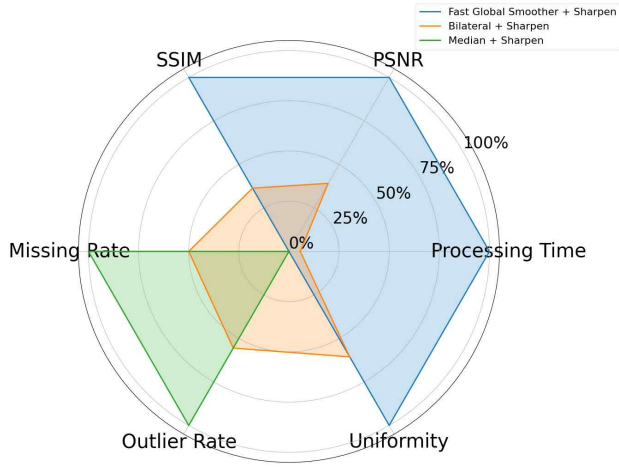


그림 11. 제조용 갭 검출 상위 필터 조합의 정량적 성능 비교를 위한 정규화 레이더 차트[3],[4],[5],[6]
Fig 11. Normalized Radar Chart for Quantitative Performance Comparison of Top Filter Combinations in Manufacturing Gap Inspection[3],[4],[5],[6]

처리 시간(s), PSNR(dB), SSIM, 누락률(%), 이상치율(%), 균일성(표준편차의 역수) 등 6개의 핵심 지표를 포함하였으며, 서로 다른 단위를 0~1 범위로 정규화하여 직접 비교가 가능하도록 하였다[5],[6]. 차트를 통해 계산 효율성, 화질, 검출 신뢰성 간의 트레이드오프를 직관적으로 확인할 수 있으며, Fast Global Smoother + Sharpen 조합이 상위 후보군 중 가장 균형 잡힌 성능을 보임을 알 수 있다[3],[4],[5],

[6]. 레이다 차트 결과, Fast Global Smoother + Sharpen 조합은 모든 지표에서 균형 잡힌 성능을 나타내었으며, Bilateral + Sharpen 및 Median + Sharpen 조합은 특정 환경에서 상대적으로 우수한 성능을 보였다[3],[4]. 이는 통계적 정량 지표(Table 1)와 시각적 평가를 결합하여 후보 필터 선정 근거를 강화하며, 제조 라인 조건별 최적 필터 선택과 하이브리드 필터 전략 설계에 유용한 정보를 제공한다[3],[4],[5].

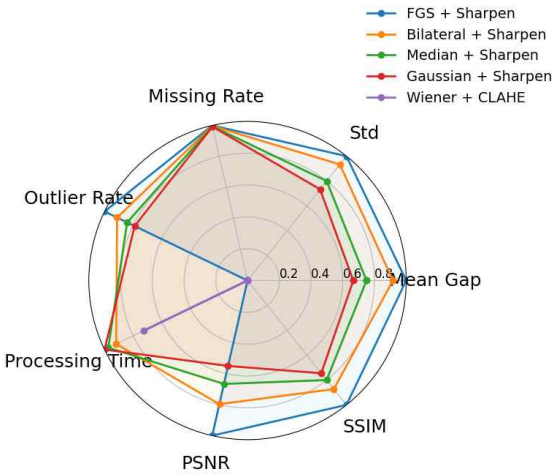


그림 12. 성능 지표 레이더 차트 (필터 조합, 평균 ROI 갭, 표준편차, 누락률(%), 이상치율(%), 처리시간(s/이미지), 피크 신호대 잡음비(dB), 구조 유사도 지수)
Fig 12. Table of Performance Metrics (Filter Combination, Average ROI Gap, Standard Deviation, Miss Rate(%), Outlier Rate(%), Processing Time(s/image), PSNR(dB), SSIM)[3],[4],[5],[6]

이를 통해 각 필터 조합 간의 트레이드오프를 직관적으로 확인할 수 있으며, Fast Global Smoother + Sharpen 조합이 전체적으로 균형 잡힌 성능을 제공함을 시각적으로 확인할 수 있었다[3],[4],[5],[6]. Bilateral, Median, Gaussian 필터 조합도 특정 환경에서 우수한 성능을 보였으며, 하이브리드 필터 전략(상단/하단 영역별 적용)을 통해 조명 및 반사 변화에 따른 이진화 안정성을 더욱 높일 수 있었다[3],[4],[5],[6].

종합적으로, 단일 필터만으로는 노이즈 제거, 엣지 보존, ROI 균일성을 동시에 확보하기 어렵다는 점이 확인되었으며, 후보 필터군 선별 시 이진화 품질 기반 정량 지표를 중심으로 평가하는 것이 필요함을 알 수 있었다[3],[4],[5],[6]. 본 연구에서는 Fast Global Smoother + Sharpen, Bilateral, Median 조합이 이진화 품질과 안정성 측면에서 우수하였으며, ROI 내 밝기 균일성 확보와 엣지 보존 능력을 동시에 제공하여 실제 제조용 갭 검출에서 신뢰성 있는 결과를 얻을 수 있음을 확인하였다[3],[4],[5],[6]. 이를 통해 제조 현장에서 필터 최적화와 하이브리드 이진화 전략 설계를 위한 실질적 근거를 제공할 수 있다[3],[4],[5],[6].

V. 결 론

본 연구에서는 제조용 갭 검사에서 이미지 기반 이진화의 신뢰성을 향상시키기 위해 동적 ROI 정렬, 1D 프로젝션 기반 갭 검출, 다양한 전처리 필터 및 필터 조합 평가를 통합한 파이프라인을 제안하고, 1000장 단위의 배치 실험을 통해 성능을 검증하였다[1],[2],[3],[4]. 제안된 접근에서는 YOLO 기반 키포인트 추출 후 회전 및 병렬 이동을 통해 ROI를 정규화함으로써 카메라 흔들림, 물체 위치 변화, 촬영 각도 편차 등 현실적 제조 환경 조건에서 발생할 수 있는 ROI 위치 불일치를 효과적으로 보정하였으며, 그 결과 갭 검출 누락률과 이상치 발생률이 현저히 감소하였다[1],[2]. 특히, 동적 ROI를 기준으로 6개 샘플 라인에서 수행한 1D 프로젝션과 연속 검정 픽셀 그룹 통합 전략은 중간 흰색 노이즈로 인한 검출 오류를 최소화하는 데 유효하였으며, ROI 내부 밝기 균일성 지표(Group Mean Difference Sum, Group Std Deviation Sum)를 활용하여 단순 화질 지표(PSNR, SSIM)만으로는 포착할 수 없는 지역적 불균형과 이상치를 보완하였다[5],[6]. 이를 통해 본 연구에서는 이진화 성능과 실제 갭 측정 정확도를 명확히 구분하고, 두 지표 간의 정량적 상관관계를 평가할 수 있음을 입증하였다[5],[6].

전처리 필터 분석 결과, Fast Global Smoother + Sharpen 조합은 노이즈 억제, 엣지 보존, ROI 내 밝기 균일성을 동시에 만족하며, 실제 갭 검출 정확도 측면에서도 균형 잡힌 성능을 나타내었다[3],[4]. Bilateral, Median, Gaussian 필터 조합도 특정 환경에서 우수한 성능을 보였으나, Wiener 필터는 과도한 평탄화로 갭 검출 실패 사례가 발생하였고, Anis

otropic 필터는 엣지 보존에는 유리하나 처리 시간이 길어 실무 적용에는 제한이 있었다[3],[4]. 이러한 결과는 단일 필터만으로는 노이즈 제거, 엣지 보존, ROI 균일성, 실제 갭 검출 정확도를 동시에 확보하기 어렵다는 점을 시사하며, 상단/하단 영역별 분리 적용, threshold 차별화 등 하이브리드 필터 전략이 필요함을 보여준다[3],[4],[7].

본 연구는 각 필터 조합의 처리 시간, 누락률, 이상치율, PSNR, SSIM, ROI 내 균일성 등 정량 지표를 종합적으로 고려하여 실무 적용 가능성을 평가하였으며, 단순 화질 평가만으로는 제조 공정에서 신뢰성 있는 갭 검출 전략 설계가 어렵다는 점을 명확히 보여주었다[3],[4],[5],[6]. 특히 Fast Global Smoother + Sharpen 조합과 동적 ROI, 그룹 합치기 규칙의 결합은 제조 환경에서 즉시 적용 가능한 균형점을 제공하며, 조명, 반사, 소재 특성 변화와 같은 환경 변수에 따라 필터와 임계값을 적절히 조정함으로써 최적 성능을 유지할 수 있다[3],[4],[7].

후속 연구에서는 학습 기반 denoiser(DnCNN, Noise2Noise, U-Net 등)를 기존 필터 조합과 비교 분석하여 이진화 품질과 실제 갭 측정 정확도의 향상 가능성을 정량적으로 평가할 계획이다[8],[9],[10]. 특히 학습 기반 접근이 환경 변화에 대한 적응력과 노이즈 억제 성능을 얼마나 개선할 수 있는지, ROI 기반 갭 검출 성능과의 상관관계를 수치적으로 분석할 예정이며, 누락률 감소 목표(예: 기존 1% → 0.5%)와 이상치율 개선 목표를 명확히 설정할 예정이다[8],[9],[10]. 또한 상단/하단 분리 전략과 하이브리드 임계값 적용을 포함한 적응형 파이프라인을 구축함으로써 다양한 제조 조건에서도 일관적이고 신뢰성 있는 갭 검출 솔루션을 제공할 수 있는 기반을 마련하고자 한다[3],[4],[7].

결론적으로, 본 연구에서 제안한 파이프라인은 이진화 성능, ROI 내 밝기 균일성, 실제 갭 측정 정확도, 처리 효율성을 종합적으로 고려하여 제조 현장에서 실무 적용이 가능한 신뢰성 있는 갭 검출 전략을 제공하며, 향후 학습 기반 denoiser와 적응형 하이브리드 전략을 결합할 경우 보다 높은 정확도와 환경 적응성을 달성할 수 있을 것으로 기대된다[3].[4].[8].[9].[10].

참 고 문 헌

[1] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian,
“Image denoising by sparse 3-D transform-domain collaborative filtering,”
IEEE Transactions on Image Processing, vol. 16, no. 8, pp. 2080–2095, Aug. 2007, doi: 10.1109/TIP.2007.901238.

[2] K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang,
“Beyond a Gaussian denoiser: Residual learning of deep CNN for image denoising,”
IEEE Transactions on Image Processing, vol. 26, no. 7, pp. 3142–3155, Jul. 2017, doi: 10.1109/TIP.2017.2662206.

[3] J. Lehtinen et al.,
“Noise2Noise: Learning image restoration without clean data,”
in Proc. 35th Int. Conf. on Machine Learning (ICML), Stockholm, Sweden, 2018, pp. 2965–2974, doi: 10.48550/arXiv.1803.04189.

[4] O. Ronneberger, P. Fischer, and T. Brox,
“U-Net: Convolutional networks for biomedical image segmentation,”
in Proc. Int. Conf. on Medical Image Computing and Computer-Assisted Intervention (MICCAI), 2015, pp. 234–241, doi: 10.1007/978-3-319-24574-4_28.

[5] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli,
“Image quality assessment: From error visibility to structural similarity,”
IEEE Transactions on Image Processing, vol. 13, no. 4, pp. 600–612, Apr. 2004, doi: 10.1109/TIP.2003.819861.

[6] P. Perona and J. Malik,
“Scale-space and edge detection using anisotropic diffusion,”
IEEE Transactions on Pattern Analysis and Machine In

telligence, vol. 12, no. 7, pp. 629-639, Jul. 1990, doi: 10.1109/34.56205.

[7] C. Tomasi and R. Manduchi,
"Bilateral filtering for gray and color images,"
in Proc. IEEE Int. Conf. on Computer Vision (ICCV), 1998, pp. 839-846, doi: 10.1109/ICCV.1998.710815.

[8] K. He, J. Sun, and X. Tang,
"Guided image filtering,"
IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 35, no. 6, pp. 1397-1409, Jun. 2013, doi: 10.1109/TPAMI.2012.213.

[9] D. L. Donoho,
"De-noising by soft-thresholding,"
IEEE Transactions on Information Theory, vol. 41, no. 3, pp. 613-627, May 1995, doi: 10.1109/18.382009.

[10] K. Zuiderveld,
"Contrast limited adaptive histogram equalization,"
in Graphics Gems IV, P. S. Heckbert, Ed. San Diego, CA: Academic Press, 1994, pp. 474-485, doi: 10.1016/B978-0-12-336156-1.50061-6.

[11] N. Otsu,
"A threshold selection method from gray-level histograms,"
IEEE Transactions on Systems, Man, and Cybernetics, vol. 9, no. 1, pp. 62-66, Jan. 1979, doi: 10.1109/TSMC.1979.4310076.

[12] J. Sauvola and M. Pietikäinen,
"Adaptive document image binarization,"
Pattern Recognition, vol. 33, no. 2, pp. 225-236, Feb. 2000, doi: 10.1016/S0031-3203(99)00055-2.

[13] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi,
"You only look once: Unified, real-time object detection,"
in Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 779-788, doi: 10.1109/CVPR.2016.91.

[14] D. Kosmopoulos, K. Nikolakopoulos, and S. Tzafestas,
"Automated inspection of gaps on the automobile production line through stereo vision and specular reflection,"
International Journal of Advanced Manufacturing Technology, vol. 17, no. 10, pp. 683-690, 2001, doi: 10.1007/s001700170106.

[15] A. Ghamisi and H. Najjaran,
"Gap and overlap detection in automated fiber placement,"
arXiv preprint, arXiv:2305.01439, 2023, doi: 10.48550/arXiv.2305.01439.